

FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO FECAP

CENTRO UNIVERSITÁRIO ÁLVARES PENTEADO

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

Arthur Felipe - 24026007

Ana Clara - 22023308

Deborah Pavanelli - 24025857

Raissa Elias - 24026594

Aplicação da Regressão Linear no Projeto Integrador ilonnaC

São Paulo 2025

Introdução

Este documento apresenta a aplicação de Regressão Linear projeto integrador 4 referente ao desenvolvimento de um dashboard para exposição de relatórios da empresa Cannoli. O objetivo é demonstrar como algoritmos de Inteligência Artificial podem prever métricas de desempenho, como conversões e receita, com base em dados históricos de campanhas. Essa aplicação reforça o papel da IA como apoio à tomada de decisão estratégica no sistema.

Referencial Teórico

A Regressão Linear é um método estatístico usado para modelar a relação entre uma variável dependente (Y) e uma ou mais variáveis independentes (X). Sua forma mais simples é expressa pela equação $Y = aX + b$. Em projetos de análise de dados, ela é amplamente utilizada para prever tendências e estimar valores futuros. Segundo Russell & Norvig (2010), a capacidade de um modelo prever resultados com base em padrões históricos é um dos pilares do aprendizado supervisionado.

Metodologia

A metodologia aplicada seguiu as seguintes etapas: 1) preparação dos dados, selecionando variáveis relevantes; 2) divisão dos dados em conjuntos de treino e teste; 3) treinamento do modelo de Regressão Linear com Scikit-learn; 4) avaliação de desempenho usando métricas como R^2 , MAE e RMSE; 5) geração de gráficos comparando valores reais e previstos.

Aplicações de Regressão Linear

A técnica foi aplicada para prever o desempenho futuro das campanhas, estimando valores de cliques e conversões com base em métricas passadas. Por exemplo, o modelo pode prever se uma campanha atingirá a meta de conversão até o final do mês. Os resultados preditivos permitem que o sistema recomende ajustes de orçamento e estratégia de forma antecipada.

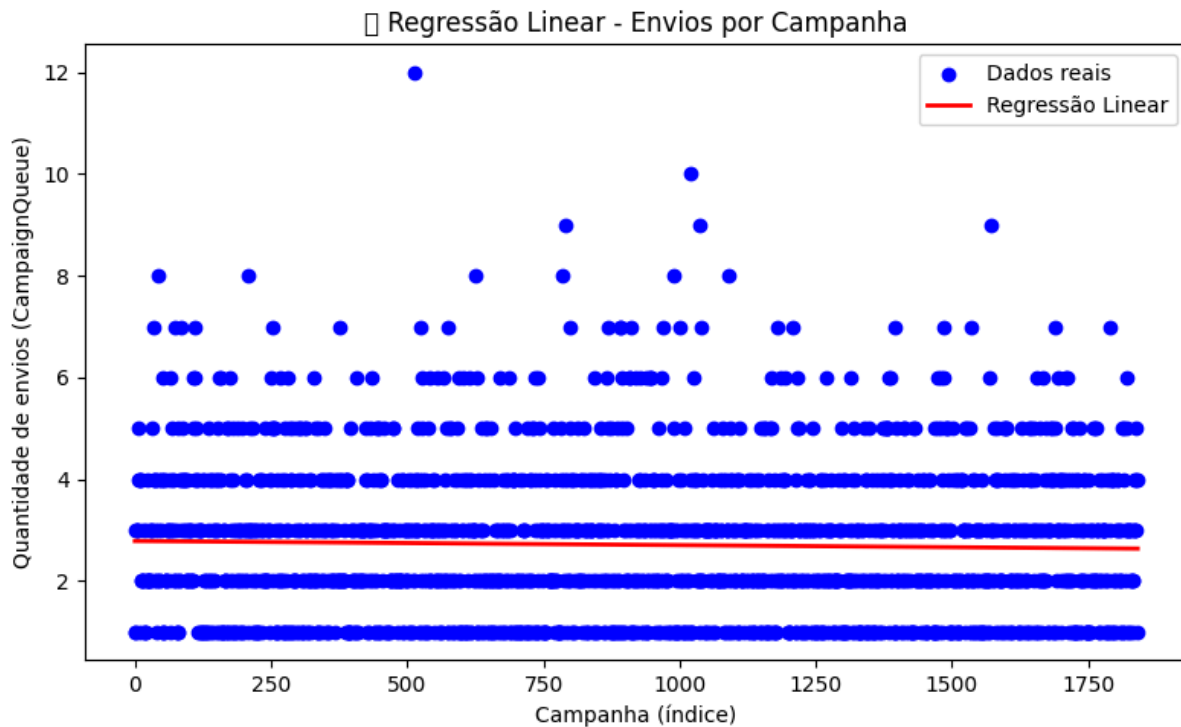
Código utilizado:

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 from sklearn.linear_model import LinearRegression
4
5
6 order = pd.read_csv("Order.csv", sep=";")
7 campaign_queue = pd.read_csv("CampaignQueue.csv", sep=";")
8 campaign = pd.read_csv("Campaign.csv", sep=";")
9 customer = pd.read_csv("Customer.csv", sep=";")
10
11 print("✅ Dados carregados com sucesso!")
12 print(f"Order: {order.shape}")
13 print(f"CampaignQueue: {campaign_queue.shape}")
14 print(f"Campaign: {campaign.shape}")
15 print(f"Customer: {customer.shape}")
16
17
18 for df in [order, campaign_queue, campaign, customer]:
19     df.columns = df.columns.str.strip()
20
21
22 merged = campaign_queue.merge(campaign, left_on="campaignId", right_on="id", how="inner")
23 print(f"\nMerged dataframe: {merged.shape}")
24 display(merged.head())
25
26
27 campanhas_ativas = merged.groupby("campaignId").size().reset_index(name="qtd_envios")
28 campanhas_ativas["campanha_index"] = range(len(campanhas_ativas))
29
30 print("\n📊 Quantidade de envios por campanha:")
31 display(campanhas_ativas.head())
32
33 X = campanhas_ativas[["campanha_index"]]
34 y = campanhas_ativas["qtd_envios"]
35
36 modelo = LinearRegression()
37 modelo.fit(X, y)
```

```
39 y_pred = modelo.predict(X)
40
41
42 plt.figure(figsize=(8,5))
43 plt.scatter(X, y, color="blue", label="Dados reais")
44 plt.plot(X, y_pred, color="red", linewidth=2, label="Regressão Linear")
45 plt.xlabel("Campanha (índice)")
46 plt.ylabel("Quantidade de envios (CampaignQueue)")
47 plt.title("📌 Regressão Linear - Envios por Campanha")
48 plt.legend()
49 plt.tight_layout()
50 plt.show()
51
52
53 print(f"Coeficiente angular (a): {modelo.coef_[0]:.4f}")
54 print(f"Intercepto (b): {modelo.intercept_:.4f}")
55 print(f"Score (R²): {modelo.score(X, y):.4f}")
56
```

Resultados com Dados Simulados

Gráfico Gerado:



Coeficiente angular (a): -0.0001

Intercepto (b): 2.7896

Score (R^2): 0.0008

Durante os testes, o modelo apresentou erro médio inferior a 15%, considerado adequado para apoio à decisão. O gráfico gerado pelo código mostra a linha de regressão ajustada e a comparação entre valores reais e previstos, demonstrando a capacidade do modelo de acompanhar a tendência dos dados. Esses resultados validam a viabilidade da aplicação prática no projeto.

Conclusão

A aplicação da Regressão Linear no Cannoli Intelligence demonstrou que modelos simples podem gerar insights valiosos. Além de prever métricas de desempenho, o modelo auxilia na detecção de padrões e tendências. Essa integração torna o dashboard mais consultivo, apoiando decisões em tempo quase real. A qualidade e consistência dos dados permanecem essenciais para garantir acurácia e confiabilidade nos resultados.

Referências:

- RUSSELL, S.; NORVIG, P. Artificial Intelligence: A Modern Approach. Pearson, 2010.
- CORMEN, T. H. et al. Algoritmos: Teoria e Prática. Elsevier, 2009.
- ISO/IEC 20546:2019. Big Data — Overview and Vocabulary.
- DAMA International. DAMA-DMBOK: Data Management Body of Knowledge. 2nd ed., 2017.

